

Aplicação de Métodos de Aprendizagem Não Supervisionada e Supervisionada no Conjunto de Dados *Airline Passenger Satisfaction*

Ana Mafalda, up202207123

Rafaela Pinto, up202004330

20 de maio de 2026

Introdução

Para a realização deste projeto foi utilizado o dataset “*Airline Passenger Satisfaction*”, retirado da plataforma *Kaggle*. [2] O dataset contém informação relativa à satisfação de passageiros de companhias aéreas, incluindo 129 880 observações e 23 variáveis, entre as quais se encontra uma variável resposta associada ao nível de satisfação do passageiro. As variáveis disponíveis incluem características demográficas dos passageiros, informação relativa ao voo e ao tipo de viagem, bem como avaliações de diferentes aspetos do serviço prestado, tais como conforto, entretenimento, limpeza, qualidade do serviço e atrasos.

O principal objetivo deste trabalho consiste em analisar os fatores associados à satisfação dos passageiros e identificar possíveis padrões presentes nos dados. Para tal, serão aplicadas técnicas de análise multivariada, incluindo métodos não supervisionados e supervisionados, lecionados ao longo da cadeira de Métodos Estatísticos em Data Mining.

Dados

O conjunto de dados inclui variáveis quantitativas contínuas, variáveis categóricas binárias e uma variável categórica com três categorias. Muitas das variáveis representam avaliações atribuídas pelos passageiros relativamente a diferentes aspetos do serviço, sendo tratadas como variáveis ordinais. [2]

Variável	Descrição	Tipo
Gender	Gênero do passageiro (Male/Female)	Categórica
Customer Type	Tipo de passageiro (Loyal/Disloyal)	Categórica
Age	Idade do passageiro	Tratada como contínua, devido à quantidade de dados
Type of Travel	Tipo de viagem (Business/Personal)	Categórica
Class	Classe do voo (Business/Eco/Eco Plus)	Categórica
Flight Distance	Distância do voo	Contínua
Inflight Wifi Service	Avaliação do Wifi durante o voo	Ordinal
Departure/Arrival Time Convenient	Avaliação da conveniência do horário de partida/chegada	Ordinal
Ease of Online Booking	Avaliação da facilidade de marcação de voo online	Ordinal
Gate Location	Avaliação da localização do local de embarque	Ordinal
Food and Drink	Avaliação da comida e bebida durante o voo	Ordinal
Online Boarding	Avaliação do embarque online	Ordinal
Seat Comfort	Avaliação do conforto do lugar no avião	Ordinal
Inflight Entertainment	Avaliação do entretenimento durante o voo	Ordinal
On-board Service	Avaliação do serviço a bordo	Ordinal
Leg Room Service	Avaliação do espaço para as pernas	Ordinal
Baggage Handling	Avaliação do tratamento de malas	Ordinal
Checkin Service	Avaliação do serviço de Check-in	Ordinal
Inflight Service	Avaliação do serviço no voo	Ordinal
Cleanliness	Avaliação da limpeza	Ordinal
Departure Delay in Minutes	Atraso de partida (em minutos)	Contínua
Arrival Delay in Minutes	Atraso de chegada (em minutos)	Contínua
Satisfaction	Satisfação (satisfeito/neutro ou insatisfeito)	Categórica

Tabela 1: Nome das variáveis, descrição das mesmas e o seu tipo.

Análise Univariada

A análise das variáveis contínuas foi feita através de *boxplots* (figura 1). Conseguimos analisar que a variável *Age* é a única que tem uma distribuição de valores aproximadamente simétricos. As restantes apresentam uma assimetria à direita e a presença de vários *outliers*. É notória também a concentração de valores baixos nas variáveis *Departure Delay* e *Arrival Delay*. A tabela seguinte contém as estatísticas descritivas destas variáveis.

Variável	Média	Mediana	Minimo	Q1	Q3	Máximo	Desvio-padrão
Age	39,43	40	7	27	51	85	15,12
Flight Distance	1190,21	844	31	414	1744	4983	997,53
Departure Delay	14,64	0	0	0	12	1592	37,93
Arrival Delay	15,09	0	0	0	13	1584	38,47

Tabela 2: Estatísticas descritivas das variáveis contínuas.




Figura 1: *Boxplots* das variáveis contínuas.

Para as variáveis ordinais, foram feitos gráficos de barras com as frequências absolutas de cada valor (figura 2). É observável que na maioria das variáveis vemos uma ”escadinha ascendente”, ou seja, as avaliações positivas (3, 4 e 5) são mais proeminentes que as negativas. Mas nas variáveis *Ease of Online Booking*, *Gate Location* e *Inflight Wifi Service* vemos uma distribuição aproximadamente normal. Isto demonstra que estes são os aspetos que têm de melhorar mais nas viagens de avião.




Figura 2: Gráficos de barras para as variáveis ordinais.

Por último, as variáveis categóricas também foram analisadas através de gráficos de barras. Vemos através da figura 3, que as variáveis *Gender* e *Satisfaction* são aproximadamente equilibradas (principalmente *Gender*). As restantes são muito desequilibradas.



Figura 3: Gráficos de barras para as variáveis categóricas.

Análise Bivariada

Nesta secção é analisada a correlação entre as diversas variáveis. Para isso, foi criado um gráfico de correlações (de spearman) entre as variáveis contínuas (figura 4). É perceptível a grande correlação positiva entre *Departure Delay* e *Arrival Delay*, algo que é natural, pois se um avião se atrasa a descolar, atrasa-se a chegar ao destino.




Figura 4: Gráfico de correlações entre variáveis contínuas.

As tabelas de contingência e os testes do qui-quadrado evidenciaram uma associação estatisticamente significativa entre *Satisfaction* e as variáveis categóricas consideradas, com *p-value* inferior a $2,2 \times 10^{-16}$.

Análise Multivariada

0.1 Métodos de Aprendizagem Não Supervisionada

Foram aplicados múltiplos métodos de aprendizagem não supervisionada com o objetivo de identificar padrões e estruturas latentes nos dados, não recorrendo portanto à variável *target*.

(variável *satisfaction*) no processo de modelação. Estes métodos não procuram reproduzir diretamente as classes da variável resposta, mas sim identificar agrupamentos naturais no espaço das variáveis explicativas. Por esse motivo, o número de clusters obtido pode não coincidir com o número de categorias da variável *target*. Assim, apesar da variável de satisfação ser binária, é perfeitamente possível que os métodos de *clustering* identifiquem múltiplos grupos distintos, refletindo diferentes perfis de passageiros em termos das características da viagem e da experiência reportada.

Antes de aplicarmos os seguintes métodos, foi feito um tratamento de dados de modo a prepará-los para a aplicação dos métodos.

Verificou-se a existência de valores omissos principalmente na variável “Arrival Delay in Minutes”, tendo sido removidas as observações incompletas, visto representar uma pequena percentagem do número total de observações (0,014%). Antes da aplicação dos métodos, procedeu-se à codificação das variáveis categóricas, de forma a permitir a sua utilização em algoritmos baseados apenas em variáveis numéricas. As variáveis binárias com apenas 2 classes, *Gender*, *Customer Type* e *Type of Travel* foram transformadas para representação numérica (0/1 - ver tabelas 3, 4 e 5). Para a variável Class, que apresenta três categorias distintas sem ordenação intrínseca, foi aplicada a técnica de *one-hot encoding*. [5] Esta abordagem consiste na criação de variáveis indicadoras binárias para cada categoria (Eco, Eco Plus e Business), evitando a imposição de uma relação ordinal artificial entre as classes. Após esta transformação, a variável original Class foi removida do conjunto de dados. Estas transformações são fundamentais, uma vez que modelos baseados em distâncias e distribuições contínuas requerem variáveis numéricas e podem ser sensíveis à introdução de codificações ordinais indevidas. O *one-hot encoding* garante, assim, uma representação adequada das variáveis categóricas, preservando a sua estrutura original sem distorcer as relações entre observações.

	Female	Male
Gender	0	1

Tabela 3: Codificação da variável *Gender*.

	Loyal	Disloyal
Customer Type	0	1

Tabela 4: Codificação da variável *Customer type*.

	Business	Personal
Type of Travel	0	1

Tabela 5: Codificação da variável *Type of travel*.

0.1.1 Análise de Componentes Principais - ACP

Com o objetivo de reduzir a dimensionalidade do conjunto de dados e eliminar redundância entre variáveis, aplicou-se uma Análise de Componentes Principais (ACP). Esta técnica permite transformar o conjunto original de variáveis correlacionadas num novo conjunto de componentes ortogonais, denominadas componentes principais, que retêm a maior parte da variabilidade presente nos dados.

Procedeu-se primeiramente à análise da matriz de correlações entre variáveis, com o objetivo de identificar relações lineares fortes e possíveis situações de redundância de informação. Esta etapa é particularmente importante no contexto da ACP, uma vez que a técnica procura precisamente explorar a correlação entre variáveis para construir componentes principais que concentrem a variabilidade dos dados em dimensões reduzidas. Quando existem correlações elevadas entre variáveis, torna-se possível representar grande parte da informação original através de um número inferior de componentes, aumentando a eficiência da redução de dimensionalidade. A análise efetuada revelou uma correlação elevada entre as variáveis *Departure Delay in Minutes* e *Arrival Delay in Minutes*, indicando que ambas transportavam informação muito semelhante sobre atrasos dos voos. De forma a reduzir redundância e simplificar o conjunto de dados, optou-se pela remoção da variável *Arrival Delay in Minutes*. Adicionalmente, verificou-se que a variável *Gender* apresentava correlações pouco significativas com as restantes variáveis, evidenciando um reduzido contributo para a estrutura global dos dados. Assim, esta variável foi removida antes das análises subsequentes, com o objetivo de simplificar o modelo e reduzir ruído potencialmente irrelevante para a segmentação dos passageiros. Estas decisões de pré-processamento permitiram obter uma representação mais compacta e informativa dos dados, favorecendo a eficácia das etapas posteriores de redução de dimensionalidade e *clustering*.

Antes da aplicação da ACP, procedeu-se à standardização das variáveis através da utilização de variáveis centradas e reduzidas (no código traduz-se a fazer "scale. = TRUE"). Esta etapa é necessária devido às diferentes escalas e amplitudes das variáveis originais, garantindo que nenhuma variável domina a análise apenas por apresentar maior variância.

Após o ajustamento da ACP, foram analisados diferentes critérios para determinar o número adequado de componentes principais a reter:

1. Critério de Pearson: Variância explicada acumulada, procurando preservar aproximadamente 80% da variabilidade total dos dados;
2. Gráfico do cotovelo (*elbow method*): identificar o ponto a partir do qual o ganho adicional de variância explicada se torna reduzido;
3. Critério de Kaiser: retenção das componentes com valores próprios superiores a 1.

Com base na combinação destes critérios, optou-se pela retenção de **sete** componentes principais, consideradas suficientes para representar a estrutura essencial dos dados com menor complexidade dimensional.

Importance of components:							
	PC1	PC2	PC3	PC4	PC5	PC6	PC7
Standard deviation	2.0843	1.5548	1.4968	1.47981	1.22933	1.07740	1.00621
Proportion of Variance	0.1975	0.1099	0.1018	0.09954	0.06869	0.05276	0.04602
Cumulative Proportion	0.1975	0.3073	0.4092	0.50872	0.57742	0.63018	0.67620
	PC8	PC9	PC10	PC11	PC12	PC13	PC14
Standard deviation	0.99620	0.97245	0.90521	0.83189	0.75796	0.69381	0.68001
Proportion of Variance	0.04511	0.04298	0.03725	0.03146	0.02611	0.02188	0.02102
Cumulative Proportion	0.72131	0.76429	0.80154	0.83300	0.85911	0.88099	0.90201
	PC15	PC16	PC17	PC18	PC19	PC20	PC21
Standard deviation	0.65384	0.60490	0.57684	0.56027	0.5409	0.4965	0.42028
Proportion of Variance	0.01943	0.01663	0.01512	0.01427	0.0133	0.0112	0.00803
Cumulative Proportion	0.92144	0.93807	0.95320	0.96747	0.9808	0.9920	1.00000
	PC22						
Standard deviation	1.262e-13						
Proportion of Variance	0.000e+00						
Cumulative Proportion	1.000e+00						

Figura 5: Sumário da ACP aplicada.




Figura 6: Gráfico do Cotovelo.

Posteriormente, analisaram-se os *loadings* das componentes principais, correspondentes às correlações entre as variáveis originais e cada componente. Para facilitar a interpretação, foram destacadas as variáveis com valores absolutos de *loading* superiores a 0.30, consideradas as mais relevantes na definição de cada componente.




Figura 7: *Loadings* das Componentes Principais.

A análise dos *loadings* permitiu associar cada componente principal a uma dimensão interpretável do comportamento dos passageiros:

1. PC1 — qualidade global do serviço a bordo;
2. PC2 — conveniência e serviços digitais;
3. PC3 — conforto e serviços complementares;
4. PC4 — tipo de viagem e classe;
5. PC5 — perfil do passageiro;
6. PC6 — classe do voo;

7. PC7 — pontualidade e atrasos.

Esta etapa revelou-se particularmente importante para reduzir a complexidade do conjunto de dados e evidenciar estruturas latentes posteriormente utilizadas na análise de *clustering*.

Optou-se por apresentar apenas a projeção das observações nas componentes PC1 e PC2, por corresponderem às componentes com maior variância explicada e maior capacidade de discriminação entre os grupos de satisfação. A representação das observações nas duas primeiras componentes principais (PC1 e PC2) evidencia uma separação parcial entre passageiros satisfeitos e neutros/insatisfeitos, sobretudo ao longo da PC1. Os passageiros satisfeitos tendem a concentrar-se em valores mais baixos de PC1, enquanto os restantes se distribuem maioritariamente em valores mais elevados. Apesar da existência de alguma sobreposição entre os grupos, o gráfico confirma que as componentes principais captam padrões relevantes associados ao nível de satisfação dos passageiros.




Figura 8: Gráfico PC1 vs. PC2.

0.1.2 K-Means

O método k-means é uma técnica de agrupamento que procura dividir os dados em k grupos distintos, minimizando a soma dos quadrados das distâncias entre cada observação e o centro do respetivo grupo.

Embora o algoritmo possa ser aplicado diretamente ao conjunto de dados original após normalização, a sua aplicação aos *scores* obtidos através da ACP tende a produzir soluções mais estáveis e interpretáveis. Isto deve-se à redução da dimensionalidade dos dados, da correlação entre variáveis e do ruído [3]. Neste trabalho, o método foi aplicado ao espaço reduzido definido pelas primeiras sete componentes principais, previamente selecionadas na aplicação da ACP. Os *scores* foram adicionalmente transformados através de *sphering*, ou seja, cada componente principal foi normalizada pelo respetivo desvio padrão. Esta transformação garante que todas as dimensões contribuem de forma equilibrada para o cálculo das distâncias, o que é particularmente relevante no contexto do K-Means, uma vez que o algoritmo assume implicitamente a existência de *clusters* aproximadamente esféricos no espaço das variáveis.

O número de clusters K deve ser previamente definido. A seleção do número ótimo de clusters foi suportada por múltiplos critérios de validação interna, aplicados sobre uma

amostra aleatória de 10 000 observações, considerada suficiente para preservar a estrutura global dos dados. A utilização de uma amostra deve-se à dimensão do conjunto de dados original, que tornaria computacionalmente muito dispendioso o cálculo destes índices sobre a totalidade das observações.

Numa primeira fase, foi analisada a evolução da soma total das variâncias intra-cluster (*Total Within-Cluster Sum of Squares*, WSS) para diferentes valores de K, através do método do cotovelo (*elbow method*). Observou-se uma redução acentuada do WSS até aproximadamente K=4 ou K=5. A partir desse ponto, o ganho obtido pela introdução de novos *clusters* tornou-se progressivamente menos significativo. Este comportamento sugere a existência de uma estrutura relativamente estável em torno destes valores.

Adicionalmente, foram utilizados índices internos de validação para avaliar a qualidade das soluções obtidas. Em particular, consideraram-se os índices Calinski–Harabasz, Ball–Hall e Silhouette. Enquanto o índice Calinski–Harabasz privilegia soluções com elevada separação entre clusters e reduzida variabilidade intra-cluster, o índice Ball–Hall baseia-se essencialmente na minimização da dispersão intra-cluster média. O índice Silhouette avalia simultaneamente a coesão intra-cluster e a separação entre clusters. O índice Calinski–Harabasz selecionou K=4, o índice Ball–Hall favoreceu K=6 e o índice Silhouette apontou para K=2. Apesar desta divergência, optou-se pela solução com K=4, por representar um compromisso equilibrado entre separação dos grupos, coesão interna e interpretabilidade dos resultados.




Figura 9: Gráfico de WSS.




Figura 10: Critérios de validação interna.

A solução obtida conduz à seguinte distribuição de observações pelos clusters:

- **Cluster 1:** 44795 observações (34.6%)
- **Cluster 2:** 9380 observações (7.2%)
- **Cluster 3:** 52198 observações (40.3%)
- **Cluster 4:** 23114 observações (17.9%)

Verifica-se a presença de dois *clusters* dominantes (1 e 3), que em conjunto representam aproximadamente 75% das observações, um *cluster* intermédio (4) e um *cluster* de menor dimensão (2), associado a um perfil mais específico e potencialmente mais extremo.

A análise dos centroides no espaço das componentes principais revela perfis bem diferenciados. O *cluster* 1 caracteriza-se por valores maioritariamente positivos na maioria das componentes, enquanto o *cluster* 3 apresenta tendência oposta, com valores predominantemente negativos. O *cluster* 4 exibe um padrão mais heterogéneo, sugerindo maior variabilidade interna. Por fim, o *cluster* 2 destaca-se por um comportamento mais extremo associado à sexta componente principal, indicando um grupo minoritário com características distintivas face aos restantes passageiros.

0.1.3 Clustering Hierárquico

Neste método não utilizamos os *scores* esferizados visto não ser uma necessidade neste método. Foi novamente utilizada uma amostra dos dados, uma vez que o Clustering Hierárquico requer o cálculo de uma matriz de distâncias $n \times n$, o que se torna computacionalmente inviável para o tamanho total do *dataset*.

Primeiramente, foram comparados diferentes métodos de ligação, nomeadamente: Ward linkage, Average linkage, Complete linkage e Single linkage, através da análise visual dos dendrogramas obtidos para cada método. O método de Ward foi aquele que apresentou a estrutura mais equilibrada e consistente. Os *clusters* obtidos revelaram dimensões relativamente homogéneas e uma separação hierárquica mais clara, sendo este o método selecionado para as análises subsequentes. Depois realizamos uma análise de validação interna com o objetivo de determinar o número mais adequado de *clusters*. Foram considerados valores de K entre

2 e 7, recorrendo aos seguintes índices internos de validação: Silhouette, Davies–Bouldin e Gamma.




Figura 11: Comparação dos vários dendrogramas dos 4 tipos de *linkage*.

Os resultados obtidos foram:




Figura 12: Índices de validação interna para o número de *clusters*.

Estes resultados sugerem que a solução com $K=5$ possa ser a escolha mais robusta globalmente, uma vez que foi suportada por dois dos três índices considerados. Contudo, foram também analisadas as distribuições dos clusters para diferentes cortes do dendrograma, nomeadamente para $K=5$, $K=6$ e $K=7$. Verificou-se que alguns *clusters* permaneceram inalterados à medida que o número de grupos aumentava.

Em particular, na passagem de $K=5$ para $K=6$, um dos *clusters* de maior dimensão dividiu-se em dois grupos relativamente equilibrados; na passagem de $K=6$ para $K=7$, ocorreu uma nova subdivisão equilibrada de outro *cluster* de grande dimensão.

Este comportamento evidencia estabilidade hierárquica e reforça a consistência da estrutura obtida através do método de Ward. Adicionalmente, mesmo para $K=7$, não surgiram clusters excessivamente pequenos, sugerindo ausência de fragmentação artificial dos dados. A visualização dos *clusters* através do dendrograma confirmou a existência de uma estrutura hierárquica estável e interpretável. As soluções com 6 e 7 clusters podem ser interpretadas

como refinamentos progressivos da estrutura principal identificada para $K=5$.




Figura 13: Visualização dos *clusters* no nível 5.

0.1.4 Model Based Clustering

Seguiu-se uma abordagem de Model-Based Clustering baseada em Modelos de Mistura Gaussianos (Gaussian Mixture Models, GMM), implementada através do pacote `mclust` do R. Esta metodologia assume que os dados são gerados por uma mistura finita de distribuições normais multivariadas, em que cada componente corresponde a um cluster distinto, caracterizado por um vetor de médias e uma matriz de covariância própria. O modelo foi inicialmente aplicado aos scores obtidos através da ACP, considerando as sete componentes principais previamente selecionadas.

A aplicação do modelo aos scores da ACP, com e sem standardização, conduziu de forma consistente à seleção de nove clusters. Em ambos os casos, o critério BIC indicou o modelo VVV como a estrutura de covariância mais adequada, sugerindo clusters com volumes, formas e orientações distintas e uma elevada flexibilidade na modelação das dependências multivariadas.

De forma exploratória, foi ainda avaliado o comportamento do modelo utilizando as variáveis contínuas originais, novamente com e sem standardização. Neste caso, o critério BIC manteve a seleção de nove clusters, mas identificou o modelo VEV como a estrutura de covariância mais adequada. Este modelo assume volumes e orientações distintos entre clusters, mas impõe restrições adicionais na forma das distribuições, resultando numa parametrização menos flexível do que o modelo VVV.

A comparação entre abordagens sugere que, embora a escolha do número de clusters seja robusta à transformação dos dados, a estrutura de covariância selecionada depende da representação utilizada, refletindo diferenças na forma como as relações multivariadas são captadas no espaço original versus no espaço das componentes principais.

Focando a análise no modelo obtido com `pca` e sem escalagem, para avaliar a interpretabilidade dos *clusters* obtidos pelo modelo GMM, procedeu-se à análise da distribuição da variável de *Satisfaction* em cada grupo. Observou-se uma associação clara entre determinados *clusters* e os níveis de satisfação dos passageiros. Em particular, os *clusters* 1 e 3 apresentaram uma predominância de passageiros satisfeitos, com proporções superiores a 98%, sugerindo que estes grupos capturam perfis associados a níveis elevados de satisfação global. Por outro

lado, os *clusters* 2, 4, 6, 7 e 8 foram fortemente dominados por passageiros classificados como *neutral or dissatisfied*, com proporções superiores a 74%, indicando perfis associados a níveis mais baixos de satisfação. Adicionalmente, os *clusters* 5 e 9 apresentaram distribuições mais equilibradas entre as duas classes de satisfação, sugerindo a existência de grupos intermédios ou menos bem definidos em termos do nível de satisfação dos passageiros.

No seu conjunto, estes resultados indicam que a segmentação obtida pelo modelo possui relevância interpretativa, uma vez que os *clusters* refletem diferenças estruturais nos perfis de satisfação dos passageiros. A distribuição das observações pelos *clusters* revelou ainda a existência de grupos com dimensões significativamente distintas, sugerindo que determinados perfis de passageiros são mais frequentes do que outros no conjunto de dados.

Por fim, o facto de o melhor modelo corresponder a uma estrutura elipsoidal relativamente flexível reforça a ideia de que os dados apresentam heterogeneidade e relações complexas entre variáveis, as quais dificilmente seriam captadas por métodos mais restritivos, como o *K-means*, que assume implicitamente *clusters* aproximadamente esféricos.

0.1.5 Considerações sobre valores de ARI obtidos

Os resultados da validação externa, obtidos através do Adjusted Rand Index (ARI), revelaram valores globalmente próximos de zero para estes 3 últimos métodos abordados, indicando uma concordância praticamente inexistente entre as soluções de clustering e a variável binária de satisfação dos passageiros.

Este resultado sugere que a estrutura natural dos dados identificada pelos diferentes métodos não corresponde diretamente à classificação associada à variável target. No entanto, como já referido anteriormente, este comportamento não é necessariamente inesperado, uma vez que o clustering constitui uma abordagem não supervisionada, na qual os grupos são formados exclusivamente com base na semelhança entre observações, sem utilização da variável resposta.

Deste modo, embora valores mais elevados de ARI indiquem maior concordância com a variável target, valores reduzidos não implicam necessariamente uma fraca qualidade do clustering em termos da estrutura intrínseca dos dados, podendo antes refletir a existência de padrões latentes distintos da variável de satisfação.

0.2 Métodos de Aprendizagem Supervisionada

Neste trabalho foram aplicados diferentes métodos de classificação supervisionada, nomeadamente Análise Discriminante Linear (ADL), Análise Discriminante Quadrática (ADQ), Regressão Logística, Árvores de Decisão e K-Nearest Neighbors (KNN).

De forma geral, o objetivo destes métodos é modelar a relação entre um conjunto de variáveis explicativas e uma variável resposta categórica, permitindo prever a classe de novas observações e compreender os fatores que influenciam essa classificação.

Estes métodos diferem entre si na forma como fazem suposições sobre os dados e constroem o modelo: alguns são paramétricos (regressão logística, ADL e ADQ), enquanto outros são não paramétricos (Árvores de Decisão e KNN), o que permite uma comparação entre abordagens com diferentes níveis de flexibilidade.

Na aplicação destes métodos, os dados foram divididos em 70% para treino e 30% para teste com o objetivo de avaliar corretamente a capacidade de generalização do modelo. O conjunto de treino é utilizado para ajustar o modelo, ou seja, para estimar os parâmetros

ou construir a estrutura do modelo com base nos dados disponíveis. O conjunto de teste é utilizado apenas para avaliação final, permitindo medir o desempenho do modelo em dados novos, não vistos durante o treino. Esta divisão é fundamental para evitar *overfitting*, garantindo que o modelo não se ajusta apenas aos dados de treino, mas consegue também prever corretamente em dados desconhecidos.

0.2.1 Análise Discriminante Linear - ADL

A Análise Discriminante Linear é um método supervisionado de classificação que procura encontrar combinações lineares das variáveis explicativas que maximizem a separação entre grupos previamente conhecidos.

O método assume que as observações seguem uma distribuição aproximadamente normal multivariada e que as diferentes classes partilham a mesma matriz de covariâncias.

Inicialmente tentou-se analisar visualmente a separação entre classes através de gráficos "pairs()" aplicados às variáveis originais. No entanto, não foi observada uma separação clara entre passageiros satisfeitos e insatisfeitos. Tal deve-se ao facto de muitas variáveis serem discretas, ordinais ou binárias, originando forte sobreposição entre observações.

Fez-se o mesmo procedimento com as 7 componentes principais e também não se conseguiu detetar divisões claras entre grupos. Assim, optou-se por aplicar a ADL sobre as variáveis e as primeiras 7 componentes principais obtidas através da ACP, reduzindo a dimensionalidade e eliminando correlações fortes entre variáveis.

A matriz de confusão obtida (usando as variáveis) mostrou uma *accuracy* aproximada de 87%, indicando que o modelo consegue separar razoavelmente os passageiros satisfeitos dos insatisfeitos.

A matriz de confusão obtida (usando as CP's) mostrou uma *accuracy* aproximada de 83%.

Apesar de não existir separação visual evidente em gráficos bidimensionais, os resultados sugerem que existe uma separação linear num espaço multidimensional de maior dimensão.

0.2.2 Análise Discriminante Quadrática - ADQ

A Análise Discriminante Quadrática é uma extensão da ADL. Ao contrário da ADL, a ADQ permite que cada classe tenha a sua própria matriz de covariâncias, produzindo fronteiras de decisão quadráticas. Este método é mais flexível, mas também mais sensível ao ruído e ao sobreajuste.

A ADQ não pôde ser aplicada diretamente às variáveis originais devido à singularidade das matrizes de covariância, provavelmente causada por multicolinearidade e pela presença de variáveis altamente correlacionadas.

A *accuracy* obtida foi aproximadamente 83%, igual à observada na ADL.

Isto sugere que as classes já são aproximadamente linearmente separáveis no espaço das componentes principais e que a flexibilidade adicional da ADQ não trouxe melhorias relevantes.

0.2.3 Árvores de Decisão

Este método permite modelar a relação entre variáveis explicativas e uma variável resposta através de uma estrutura hierárquica de regras de decisão. O objetivo é dividir sucessivamente o espaço das variáveis em regiões cada vez mais homogêneas em relação à variável alvo, neste caso a *satisfaction*. [7]




Figura 14: Árvore de Decisão obtida.

A árvore obtida permite interpretar facilmente as regras de decisão geradas. Observou-se que as divisões mais importantes estão associadas às variáveis *Online Boarding*, *Inflight Wifi Service* e *Type of Travel*, sugerindo que estas apresentam maior poder discriminativo na explicação da satisfação dos passageiros. Em particular, a variável *Online Boarding* surge na raiz da árvore, sendo por isso a variável mais relevante na separação inicial das classes.

A árvore final é composta por cinco divisões (*splits*), correspondendo a cinco regras de decisão principais. Este nível de segmentação resulta em grupos cada vez mais específicos, onde algumas folhas finais representam apenas uma pequena percentagem do total de observações, indicando uma elevada especialização em determinadas regiões do espaço das variáveis.

A complexidade do modelo foi avaliada através do parâmetro de complexidade (*cp*), obtido com a função "printcp()", que permite analisar o erro de validação cruzada. Verificou-se que a árvore inicial já apresentava um bom equilíbrio entre complexidade e desempenho, não sendo necessário um processo de poda.

O desempenho do modelo foi avaliado no conjunto de teste, através da construção de uma matriz de confusão e do cálculo da *accuracy*. O modelo obteve uma *accuracy* de aproximadamente 89%, indicando uma boa capacidade de classificação e generalização para novos dados.

No conjunto de teste, cada observação é classificada ao percorrer a estrutura da árvore desde o nó raiz até a uma folha terminal, seguindo as regras de decisão baseadas nos valores das variáveis explicativas. A classe atribuída a cada observação corresponde à classe predominante no nó terminal onde esta é enquadrada, permitindo assim realizar a previsão da variável *satisfaction* para dados não observados.

Também foi aplicado este método com ACP, mas não se obteve resultados melhores. Obteve-se uma *accuracy* de 82%.

0.2.4 Regressão Logística

A Regressão Logística é um método supervisionado utilizado para modelar probabilidades associadas a variáveis resposta binárias. [4] O modelo estima a probabilidade de um passageiro pertencer à classe "satisfeito", utilizando como variáveis explicativas as características do serviço prestado.

O modelo foi ajustado, usando as variáveis, através da função "glm()" com família binomial.

As probabilidades previstas foram convertidas em classes utilizando um *threshold* de 0.5. A matriz de confusão mostrou uma *accuracy* aproximada de 88% tanto no treino como no teste. A proximidade entre ambas as *accuracies* sugere que o modelo generaliza bem e não apresenta sinais evidentes de *overfitting*. Também foi feita a curva de ROC (Receiver Operating Characteristic) e calculado o valor de AUC (Area Under the Curve) que deu 0.928, um valor muito perto de 1, o que significa que este modelo está muito bem ajustado aos dados. [6]

Este modelo também foi ajustado aos dados, usando as componentes principais encontradas na ACP, mas esta redução de dimensionalidade não trouxe resultados melhores.

Os resultados obtidos indicam que a satisfação dos passageiros pode ser explicada de forma eficaz através de relações aproximadamente lineares entre as variáveis explicativas e o logaritmo das odds da resposta. A partir deste método também conseguimos perceber que variáveis são menos significativas para a satisfação dos passageiros.

Mais uma vez, este modelo foi ajustado com ACP, mas não trouxe vantagem nenhuma, com uma *accuracy* de 84% obtida.

```
Coefficients: (1 not defined because of singularities)
              Estimate Std. Error z value Pr(>|z|)
(Intercept)    -5.602e+00  7.883e-02 -71.066 < 2e-16 ***
'Customer Type' -2.066e+00  3.180e-02 -64.975 < 2e-16 ***
Age            -8.893e-03  7.574e-04 -11.741 < 2e-16 ***
'Type of Travel' -2.705e+00  3.352e-02 -80.692 < 2e-16 ***
'Flight Distance' -2.134e-05  1.205e-05 -1.771  0.07657 .
'Inflight wifi service' 3.991e-01  1.215e-02 32.854 < 2e-16 ***
'Departure/Arrival time convenient' -1.322e-01  8.728e-03 -15.148 < 2e-16 ***
'Ease of online booking' -1.470e-01  1.203e-02 -12.220 < 2e-16 ***
'Gate location'  2.263e-02  9.752e-03  2.320  0.02033 *
'Food and drink'  -3.530e-02  1.139e-02 -3.098  0.00195 **
'Online boarding'  5.952e-01  1.088e-02 54.717 < 2e-16 ***
'Seat comfort'    6.087e-02  1.191e-02  5.112 3.18e-07 ***
'Inflight entertainment' 6.471e-02  1.518e-02  4.262 2.03e-05 ***
'On-board service' 3.000e-01  1.086e-02 27.619 < 2e-16 ***
'Leg room service' 2.477e-01  9.072e-03 27.300 < 2e-16 ***
'Baggage handling' 1.295e-01  1.215e-02 10.665 < 2e-16 ***
'Checkin service'  3.207e-01  9.092e-03 35.276 < 2e-16 ***
'Inflight service' 1.231e-01  1.281e-02  9.609 < 2e-16 ***
Cleanliness     2.253e-01  1.293e-02 17.420 < 2e-16 ***
'Departure Delay in Minutes' -4.782e-03  2.866e-04 -16.688 < 2e-16 ***
classeCO        -7.279e-01  2.734e-02 -26.627 < 2e-16 ***
classeCOPLUS    -8.608e-01  4.448e-02 -19.352 < 2e-16 ***
```

Figura 15: Sumário da Regressão Logística.

Podemos observar que apenas uma variável não é significativa a um nível de 0.05, *Flight Distance*. Mas também podemos dizer que a variável *Gate Location* não é muito significativa em comparação com as restantes.

0.2.5 KNN

Por último, aplicou-se o método dos K Vizinhos Mais Próximos (k-Nearest Neighbors – kNN). Este método pode ser utilizado tanto em problemas de regressão como de classificação, sendo neste caso aplicado para classificação, uma vez que a variável resposta (satisfaction) é categórica.

O algoritmo classifica novas observações com base nas classes dos k vizinhos mais próximos no espaço das variáveis explicativas. Neste contexto, foi utilizada a distância euclidiana como medida de proximidade entre observações. Uma vez que o método kNN é baseado em distâncias, tornou-se necessário proceder à normalização das variáveis, dado que estas apresentam escalas distintas. Assim, foi realizada uma standardização completa dos dados através de centragem e escalonamento (center e scale), garantindo que todas as variáveis

contribuem de forma equilibrada para o cálculo das distâncias. Adicionalmente, dado que o algoritmo kNN apresenta um custo computacional elevado, particularmente em conjuntos de dados de grande dimensão, optou-se pela utilização de uma amostra dos dados para a implementação do modelo.

A escolha do valor de k constitui um aspeto fundamental do modelo e não deve ser feita de forma arbitrária. Valores de k demasiado pequenos tornam o modelo excessivamente sensível a variações locais e ruído nos dados, aumentando o risco de *overfitting* e elevada variância. Por outro lado, valores de k demasiado elevados conduzem a fronteiras de decisão mais suaves, podendo resultar em *underfitting* e perda de capacidade discriminativa. [3]

De forma a seleccionar o valor de k mais adequado, utilizou-se validação cruzada repetida do tipo k-fold [1]. Neste procedimento, os dados foram divididos em 5 subconjuntos (5-fold cross-validation), sendo o processo repetido duas vezes com diferentes partições aleatórias dos dados. Assim, para cada valor de k considerado (entre 1 e 15), foram realizadas 10 avaliações do modelo, permitindo obter uma estimativa mais robusta e estável do desempenho preditivo no conjunto de treino. O valor k=7 foi seleccionado por apresentar a maior *accuracy* média durante a validação cruzada no conjunto de treino. Utilizando este valor, o modelo foi posteriormente aplicado ao conjunto de teste, obtendo-se uma *accuracy* de aproximadamente 91%, o que evidenciava uma boa capacidade preditiva do algoritmo para dados não utilizados durante o treino.

Com o objetivo de avaliar o impacto da redução de dimensionalidade no desempenho do classificador, aplicou-se o algoritmo k-NN aos scores das 7 componentes principais, definidas atrás aquando da aplicação da ACP.

Após a aplicação do método, verificou-se que o valor ótimo de k foi k=9, obtendo-se uma *accuracy* aproximada de 90% no conjunto de teste, valor muito semelhante ao obtido utilizando as variáveis originais.

Estes resultados sugerem que a aplicação da ACP não conduziu a melhorias significativas no desempenho preditivo do k-NN. Tal poderá indicar que as variáveis originais já apresentavam uma boa capacidade discriminativa entre as classes e um nível relativamente reduzido de ruído ou redundância prejudicial ao modelo.

Embora a ACP permita reduzir dimensionalidade e eliminar correlações lineares entre variáveis, esta técnica maximiza a variância total dos dados e não necessariamente a separação entre classes. Assim, algumas componentes potencialmente relevantes para discriminação podem ter sido parcialmente descartadas durante a redução dimensional.

Conclui-se, portanto, que neste conjunto de dados o k-NN apresentou desempenho semelhante quer utilizando as variáveis originais quer utilizando as componentes principais obtidas por ACP.

Conclusões

Accuracy	ADL	ADQ	ADec	RL	KNN
S/ACP	87%	-	89%	88%	91%
C/ACP	83%	83%	82%	84%	90%

Tabela 6: Valores de *accuracy* obtidos em todos os métodos supervisionados sem e com ACP aplicada.

Verificou-se que métodos supervisionados apresentaram desempenho substancialmente superior aos métodos não supervisionados, evidenciando que a variável satisfação possui uma estrutura discriminativa clara quando a informação de classe é utilizada explicitamente.

Entre os classificadores considerados, o KNN e as Árvores de Decisão apresentaram os melhores desempenhos preditivos, com accuracies próximas de 90%. No entanto, o KNN revelou maior custo computacional e maior sensibilidade à dimensionalidade dos dados.

A ACP revelou-se particularmente útil na simplificação da estrutura dos dados e na redução de correlações entre variáveis, embora nem sempre tenha conduzido a melhorias no desempenho preditivo.

Os métodos de clustering identificaram estruturas latentes relevantes nos dados, mas estas não coincidiram diretamente com a variável binária de satisfação, o que era expectável dada a natureza não supervisionada destes métodos.

Globalmente, conclui-se que fatores relacionados com conforto, qualidade do serviço a bordo, conveniência digital e experiência global de voo desempenham um papel determinante na satisfação dos passageiros.

Referências

- [1] Jesse John. How to use cross-validation for a knn classification model in r. <https://www.delftstack.com/howto/r/cross-validation-r/>.
- [2] unknown. Airline passenger satisfaction. <https://www.kaggle.com/datasets/teejmahal20/airline-passenger-satisfaction>.
- [3] unknown. K-nearest neighbors and curse of dimensionality. <https://www.geeksforgeeks.org/machine-learning/k-nearest-neighbors-and-curse-of-dimensionality/>.
- [4] unknown. Multinomial logistic regression. https://bookdown.org/chua/ber642_advanced_regression/multinomial-logistic-regression.html.
- [5] unknown. One hot encoding in machine learning. <https://www.geeksforgeeks.org/machine-learning/ml-one-hot-encoding/>.
- [6] unknown. Plotting roc curve in r programming. <https://www.geeksforgeeks.org/r-language/plotting-roc-curve-in-r-programming/>.
- [7] unknown. Árvores de decisão em aprendizado de máquina usando o r. <https://www.datacamp.com/pt/tutorial/decision-trees-R>.